

Машинное обучение: Лекция 2

Гаврилов Даниил

2017-2018

olavursky@gmail.com

Санкт-Петербургский Государственный Университет

Факультет Прикладной Математики и Процессов Управления

Параметризация модели

Введем параметризацию некоторой модели, которая предсказывала бы нам цену квартиры

$$y = Xw + b, w \in \mathbb{R}^k, b \in \mathbb{R}$$

Очевидно, что такая параметризация может быть описана как

$$p(y|X, w, b) = \mathcal{N}(y|Xw + b, \sigma^2)$$

Переобозначим w и b как $\theta \in \mathbb{R}^{k+1}$

X – матрица $N \times k$, где k – количество "фичей" данных, а N – кол-во наблюдений,

y – вектор $\in \mathbb{R}^N$

Maximum likelihood

Самым простым способом обучить такую модель будет найти максимум правдоподобия

$$\theta_{ML} = \operatorname{argmax}_{\theta} [p(y|X, \theta)] = \operatorname{argmax}_{\theta} [\ln(p(y|X, \theta))]$$

Maximum likelihood

Самым простым способом обучить такую модель будет найти максимум правдоподобия

$$\theta_{ML} = \operatorname{argmax}_{\theta} [p(y|X, \theta)] = \operatorname{argmax}_{\theta} [\ln(p(y|X, \theta))]$$

Как и говорили в прошлый раз, если $p(y|x, \theta) = \mathcal{N}(y|f(x, \theta), \sigma^2)$, то

$$\theta_{ML} = \operatorname{argmin}_{\theta} [(y - X\theta)^2] = \operatorname{argmin}_{\theta} [\operatorname{Loss}(X, y, \theta)]$$

Maximum likelihood

Самым простым способом обучить такую модель будет найти максимум правдоподобия

$$\theta_{ML} = \operatorname{argmax}_{\theta} [p(y|X, \theta)] = \operatorname{argmax}_{\theta} [\ln(p(y|X, \theta))]$$

Как и говорили в прошлый раз, если $p(y|x, \theta) = \mathcal{N}(y|f(x, \theta), \sigma^2)$, то

$$\theta_{ML} = \operatorname{argmin}_{\theta} [(y - X\theta)^2] = \operatorname{argmin}_{\theta} [\operatorname{Loss}(X, y, \theta)]$$

Можно показать, что $\operatorname{Loss}(X, y, \theta)$ – выпуклая функция, а потому точка, в которой ее производная будет равняться нулю, будет точкой ее минимума

Тогда

$$\begin{aligned} Loss &= (y - X\theta)^\top (y - X\theta) = \\ &= y^\top y - 2y^\top X\theta + \theta^\top X^\top X\theta \end{aligned}$$

$$\frac{\partial Loss}{\partial \theta} = -2X^\top y + 2X^\top X\theta = 0$$

$$\theta = (X^\top X)^{-1} X^\top y$$

– closed form solution для линейной регрессии

Проблемой closed form solution является:

- 1) $X^T X$ чертовски экспансивная штука – её размерность $k \times k$, поэтому если k достаточно большое, считать обратную матрицу будет не простой задачей
- 2) Мы получили closed form solution только потому, что посчитать производную линейной функции и разрешить равенство её нулю относительно параметров – тривиальная задача, однако если бы функция была сложнее, то у нас не вышло бы сделать этого.

Альтернативой closed form solution является численная минимизация функции. Она основывается на том факте, что градиент функции – это вектор, направление которого совпадает с направлением возрастания функции, а потому мы можем выбрать некоторую начальную точку для параметров θ_0 , после чего

```
 $\theta_0 \leftarrow \text{random\_number}()$   
for i in range(num_iterations) do  
     $\theta_{i+1} \leftarrow \theta_i - \text{alpha} * \frac{\partial \text{Loss}(X, y, \theta_i)}{\partial \theta}$   
end for
```

Stochastic Gradient Descent

Мы можем сделать алгоритм еще более эффективным – если мы выберем случайное подмножество данных $X_{mb} \subset X$ и аппроксимируем $\frac{\partial \text{Loss}(X, y, \theta_i)}{\partial \theta}$ как $\frac{\partial \text{Loss}(X_{mb}, y_{mb}, \theta_i)}{\partial \theta}$, то для вычисления производной нам понадобится существенно меньше вычислительных ресурсов

```
 $\theta_0 \leftarrow \text{random\_number}()$   
for  $i$  in  $\text{range}(\text{num\_iterations})$  do  
     $(X_{mb}, y_{mb}) \leftarrow \text{get\_random\_subset}(X, y)$   
     $\theta_{i+1} \leftarrow \theta_i - \text{alpha} * \frac{\partial \text{Loss}(X_{mb}, y_{mb}, \theta_i)}{\partial \theta}$   
end for
```

Maximum Posteriori

Максимум правдоподобия может давать нам не самый лучший результат, когда мы захотим проверить работу нашего алгоритма на независимых данных.

Немного лучше в этом плане ведет себя Максимум Апостериора

$$\begin{aligned}\theta_{MAP} &= \operatorname{argmax}_{\theta} [p(\theta|X, y)] = \operatorname{argmax}_{\theta} [\ln(p(\theta|X, y))] \\ &= \operatorname{argmax}_{\theta} [\ln(p(y|X, \theta)) + \ln(p(\theta))]\end{aligned}$$

Т.к. $p(\theta) \in (0; 1]$, то $\ln(p(\theta)) \in (-\infty; 0]$, то мы можем сказать, что

$$Loss = (y - X\theta)^{\top} (y - X\theta) + f(\theta), f(\theta) \in [0; \infty)$$

Например

$$f(\theta) = \|theta\|_2$$

или

$$f(\theta) = \|theta\|_1$$

$$p(\theta|X, y) = \frac{p(y|X, \theta)p(\theta)}{\int_{\theta} p(y|X, \theta)p(\theta)d\theta}$$

$$p(\hat{y}|X, y) = \int_{\theta} p(\hat{y}|X, \theta)p(\theta|X, y)d\theta$$